

Полное строгое определение локального и глобального Гессиана второго порядка в произвольной нейронной архитектуре

Аноним
Аффилиация
anonymous@example.com

June 10, 2025

Abstract

В данной статье представлено исчерпывающее математически строгое определение Гессиана второго порядка для нейронных сетей произвольной архитектуры, заданной направленным ациклическим графом. Существующие подходы к вычислению кривизны функции потерь нейронных сетей часто ограничиваются аппроксимацией Гаусса-Ньютона, учитывающей лишь часть вторых производных. В работе разработан полный формализм, учитывающий все чистые и смешанные вторые производные по входам и параметрам, кросс-блоки между разными параметрами, а также механизмы разделения параметров между узлами сети. Особое внимание уделено негладким активационным функциям через использование Clarke-Гессиана. Для тривиального графа из единственного узла без потомков и предков предложенные формулы сводятся к стандартному Гессиану $\nabla_{\theta}^2 \mathcal{L}(\theta) \in \mathbb{R}^{p \times p}$. Предложенный формализм предоставляет теоретический фундамент для углубленного анализа геометрических свойств функционала потерь и разработки более эффективных алгоритмов оптимизации нейронных сетей произвольной архитектуры.

1 Введение

Гессиан второго порядка $\nabla^2 \mathcal{L}$ играет фундаментальную роль в анализе кривизны функционала потерь и в разработке методов оптимизации нейронных сетей [Martens, 2014, Pascanu et al., 2013b]. Методы второго порядка, такие как методы Ньютона, trust-region методы и их модификации, требуют точной информации о кривизне функции потерь для эффективной оптимизации [Nocedal and Wright, 2006]. Однако в контексте глубоких нейронных сетей вычисление и хранение полного Гессиана становится вычислительно неприемлемым, что приводит к необходимости использования различных аппроксимаций.

Наиболее распространенный подход — аппроксимация Гаусса-Ньютона, которая учитывает лишь часть всех вторых производных, игнорируя существенные компоненты кривизны [Schraudolph, 2002, Martens, 2010]. В данной работе мы предлагаем *полный* формализм, закрывающий следующие пробелы в существующей литературе:

- чистые и смешанные вторые производные по *входам* каждого узла нейронной сети;
- чистые вторые производные по *параметрам*;
- кросс-блоки $\partial^2/\partial\theta_v \partial\theta_w$ между параметрами разных узлов;
- смешанные вход-параметрические производные;
- учёт "разделения" (sharing) одного вектора параметров между несколькими узлами;
- обработка негладких активационных функций через методологию Clarke-Гессиана.

Особый случай: Если архитектура нейронной сети вырождается в единственный узел без потомков и предков, все предлагаемые определения естественным образом сводятся к стандартному Гессиану $\nabla_{\theta}^2 \mathcal{L}(\theta) \in \mathbb{R}^{p \times p}$.

2 Связанные работы

Изучение геометрии функционала потерь нейронных сетей имеет долгую историю. Классические работы [Amari, 1998, Heskes, 2000] заложили основу для использования геометрической информации в оптимизации нейронных сетей. Особое значение имеет информационная геометрия и натуральный градиентный спуск, предложенный Амари [Amari, 1998].

В контексте вычисления Гессиана нейронных сетей, значительными являются работы [Martens, 2010, Martens and Sutskever, 2012], где представлены эффективные приближения Гессиана для глубоких нейронных сетей. Гаусс-Ньютон аппроксимация, которая игнорирует вторые производные функции потерь, часто применяется в практических алгоритмах из-за вычислительной эффективности и гарантии положительной полуопределенности.

Для негладких функций активации, таких как ReLU, традиционный анализ второго порядка неприменим. В работах [Clarke, 1990, Bolte and Pauwels, 2020] представлен обобщенный подход к недифференцируемым функциям через субдифференциальное исчисление и Clarke-градиенты. В нашей работе мы применяем

эти концепции непосредственно к нейронным сетям, предлагая полный формализм для анализа кривизны функции потерь.

Недавние работы [Ghorbani et al., 2019, Sagun et al., 2017] исследуют спектральные свойства Гессиана функций потерь нейронных сетей и их связь с обобщением. Наше исследование дополняет эти работы, предоставляя точный математический аппарат для вычисления всех компонентов Гессиана в произвольных архитектурах нейронных сетей.

3 Методология

3.1 Таблица обозначений

Для удобства восприятия сложных формул и структур, приведём систематизированную таблицу основных обозначений:

Table 1: Основные обозначения, используемые в работе

Символ	Определение	Размерность
v, w, u	Узлы нейронной сети	—
$G = (V, E)$	Направленный ациклический граф, представляющий нейронную сеть	—
$\text{Pa}(v)$	Множество родительских узлов узла v	—
$\text{Ch}(v)$	Множество дочерних узлов узла v	—
f_v	Вектор выходов узла v	\mathbb{R}^{d_v}
θ_v	Вектор параметров узла v	\mathbb{R}^{p_v}
\mathcal{L}	Функция потерь	\mathbb{R}
δ_v	Градиент потерь по выходу узла v	\mathbb{R}^{d_v}
$D_{u \leftarrow v}$	Якобиан преобразования от узла v к узлу u	$\mathbb{R}^{d_u \times d_v}$
D_v	Якобиан выхода узла v по его параметрам	$\mathbb{R}^{d_v \times p_v}$
$T_{u;v}$	Тензор вторых производных выхода узла u по входу от узла v	$\mathbb{R}^{d_u \times d_v \times d_v}$
$T_{u;v,w}$	Тензор смешанных вторых производных по разным входам	$\mathbb{R}^{d_u \times d_v \times d_w}$
$T_{v;w,\theta}$	Тензор смешанных производных по входу и параметрам	$\mathbb{R}^{d_v \times d_w \times p_v}$
T_v^θ	Тензор вторых производных по параметрам	$\mathbb{R}^{d_v \times p_v \times p_v}$
$H_{v,w}^f$	Блок входного Гессиана между узлами v и w	$\mathbb{R}^{d_v \times d_w}$
H_{θ_v, θ_w}	Блок параметрического Гессиана	$\mathbb{R}^{p_v \times p_w}$
$\partial_C^2 f_v$	Clarke-Гессиан узла v (для негладкого случая)	множество матриц

Remark 1 (Соглашение об индексах). В работе приняты следующие соглашения об индексах:

- i — индекс компоненты выхода узла (f_v или f_u)
- j, k — индексы компонент входов узлов
- k, ℓ — в контексте параметров, индексы компонент параметра θ_v
- v, w, u — индексы узлов в графе нейронной сети

3.2 Функциональные пространства и аналитические предпосылки

Прежде чем перейти к определению компонентов и структуры Гессияна, необходимо формализовать функциональные пространства, в которых рассматривается задача, и уточнить аналитические предпосылки анализа.

Definition 1 (Функциональные пространства). В рамках данной работы рассматриваются следующие функциональные пространства:

- \mathbb{R}^n с евклидовой нормой $\|\cdot\|_2$ — конечномерное гильбертово пространство параметров, активаций и градиентов.
- $C^2(\mathbb{R}^n, \mathbb{R}^m)$ — пространство дважды непрерывно дифференцируемых функций из \mathbb{R}^n в \mathbb{R}^m , используемое для гладкого случая.
- $C^{1,1}(\mathbb{R}^n, \mathbb{R}^m)$ — пространство непрерывно дифференцируемых функций с липшицевыми производными, используемое для негладкого случая.
- $PC^2(\mathbb{R}^n, \mathbb{R}^m)$ — пространство кусочно дважды дифференцируемых функций, где каждый кусок принадлежит C^2 , а границы кусков образуют множество меры нуль.
- $L(\mathbb{R}^n, \mathbb{R}^m)$ — пространство линейных операторов (матриц) из \mathbb{R}^n в \mathbb{R}^m с операторной нормой и нормой Фробениуса.

Assumption 1 (Регулярность функций узлов). Для каждого узла $v \in V$ нейронной сети:

1. В гладком случае (Случай A): функция узла $g_v \in C^2(\mathbb{R}^{\sum_{u \in \text{Pa}(v)} d_u}, \mathbb{R}^{d_v})$, т.е. дважды непрерывно дифференцируема по всем входам и параметрам.
2. В негладком случае (Случай B): функция узла $g_v \in PC^2(\mathbb{R}^{\sum_{u \in \text{Pa}(v)} d_u}, \mathbb{R}^{d_v})$ и локально липшицева, т.е. является кусочно дважды дифференцируемой с границами кусков, образующими множество меры нуль.

Proposition 1 (Существование и непустота Clarke-субдифференциала). *Для локально липшицевой функции $f : \mathbb{R}^n \rightarrow \mathbb{R}$, которая дифференцируема почти всюду (в смысле меры Лебега по теореме Радемакера), Clarke-субдифференциал $\partial_C f(x)$ определен и непуст во всех точках $x \in \mathbb{R}^n$. Более того, $\partial_C f(x)$ является выпуклым компактным множеством в метрическом пространстве $(L(\mathbb{R}^n, \mathbb{R}), \|\cdot\|_{op})$, где $\|\cdot\|_{op}$ — операторная норма.*

Для векторнозначных функций $F : \mathbb{R}^n \rightarrow \mathbb{R}^m$ субдифференциал определяется покомпонентно, и Clarke-Гессиан $\partial_C^2 F(x)$ также существует при соответствующих условиях локальной липшицевости и почти всюду дифференцируемости компонент градиента ∇F_i .

Эти предпосылки гарантируют корректность всех последующих определений и вычислений, связанных с дифференцированием функций узлов нейронной сети как в гладком, так и в негладком случаях.

3.3 Модель нейронной сети и обозначения

Definition 2 (Архитектура нейронной сети). *Рассматривается нейронная сеть, архитектура которой представлена в виде направленного ациклического графа (DAG) $G = (V, E)$, где V — множество узлов сети, а E — множество направленных рёбер.*

Для каждого узла $v \in V$ определены следующие компоненты:

Входы: $f_{Pa(v)} \in \prod_{u \in Pa(v)} \mathbb{R}^{d_u}$, где $Pa(v)$ — множество родительских узлов для v .

Параметры: $\theta_v \in \mathbb{R}^{p_v}$ — параметры, связанные с узлом v .

Функция узла: $f_v = g_v(f_{Pa(v)}, \theta_v) \in \mathbb{R}^{d_v}$ — отображение, преобразующее входы и параметры в выход узла v .

Функция потерь: $\mathcal{L} : \mathbb{R}^{d_{out}} \rightarrow \mathbb{R}$ — функция потерь, определённая на выходном узле $out \in V$.

В зависимости от гладкости функций узлов, выделяем два принципиально различных случая:

- **Случай А (гладкий).** Все функции узлов g_v дважды непрерывно дифференцируемы по входам и параметрам, т.е. $g_v \in C^2$.
- **Случай В (негладкий).** В сети присутствуют негладкие функции активации, такие как ReLU, max-pooling и другие. В этом случае используется концепция Clarke-Гессиана $\partial_C^2 f_v$.

Вычисление всех блоков Гессиана осуществляется в обратном топологическом порядке по графу G , начиная с выходного узла out .

3.4 Градиенты первого порядка

Для разработки полного формализма Гессиана второго порядка необходимо сначала определить производные первого порядка, которые служат основой для дальнейших вычислений:

$$\begin{aligned} \delta_v &:= \nabla_{f_v} \mathcal{L} && \in \mathbb{R}^{d_v}, \quad (\text{градиент потерь по выходу узла } v) \\ \delta_{v,i} &:= [\delta_v]_i, && i = 1, \dots, d_v, \quad (\text{компоненты градиента}) \\ D_{u \leftarrow v} &:= \frac{\partial f_u}{\partial f_v} && \in \mathbb{R}^{d_u \times d_v}, \quad (\text{якобиан по входу}) \\ D_v &:= \frac{\partial f_v}{\partial \theta_v} && \in \mathbb{R}^{d_v \times p_v}. \quad (\text{якобиан по параметрам}) \end{aligned}$$

Градиенты δ_v и якобианы $D_{u \leftarrow v}$, D_v являются основой цепного правила первого порядка и используются для вычисления производных функции потерь по параметрам сети.

3.5 Тензоры вторых производных

Для полного учёта всех вторых производных функций узлов вводятся следующие тензорные структуры:

$$\begin{aligned} [T_{u;v}]_{i,j,k} &= \frac{\partial^2(f_u)_i}{\partial(f_v)_j \partial(f_v)_k} \in \mathbb{R}^{d_u \times d_v \times d_v}, && v \in \text{Pa}(u), \\ [T_{u;v,w}]_{i,j,k} &= \frac{\partial^2(f_u)_i}{\partial(f_v)_j \partial(f_w)_k} \in \mathbb{R}^{d_u \times d_v \times d_w}, && v, w \in \text{Pa}(u), \quad v \neq w, \\ [T_{v;w,\theta}]_{i,j,k} &= \frac{\partial^2(f_v)_i}{\partial(f_w)_j \partial(\theta_v)_k} \in \mathbb{R}^{d_v \times d_w \times p_v}, && w \in \text{Pa}(v), \\ [T_v^\theta]_{i,k,\ell} &= \frac{\partial^2(f_v)_i}{\partial(\theta_v)_k \partial(\theta_v)_\ell} \in \mathbb{R}^{d_v \times p_v \times p_v}. \end{aligned}$$

Remark 2 (Тензорная нотация и правила свертки). В тензорных выражениях выше и далее приняты следующие соглашения:

- Индекс i всегда относится к компоненте выхода соответствующего узла (f_u или f_v).
- Индексы j и t относятся к компонентам входов от родительских узлов.
- Индексы α и β относятся к компонентам параметров θ_v .

- Обозначение $[T]_{i,\bullet,\bullet}$ представляет матрицу (срез тензора), полученную фиксацией индекса i .
- При умножении на скаляр $\delta_{v,i}$ подразумевается свёртка по индексу i с весовыми коэффициентами $\delta_{v,i}$.

При свертке тензоров с другими тензорами или векторами используются следующие правила:

- Для выражения $[T_{u;v}]_{i,j,k}\delta_{u,i}$ результатом является матрица размерности $d_v \times d_v$ с элементами $\sum_{i=1}^{d_u} [T_{u;v}]_{i,j,k}\delta_{u,i}$.
- При матричном умножении $D_{u \leftarrow v}^\top H_{u,u}^f D_{u \leftarrow w}$ индексы сворачиваются согласно правилам матричного произведения, где $D_{u \leftarrow v}^\top \in \mathbb{R}^{d_v \times d_u}$, $H_{u,u}^f \in \mathbb{R}^{d_u \times d_u}$, $D_{u \leftarrow w} \in \mathbb{R}^{d_u \times d_w}$.
- Тензорное выражение $\sum_{i=1}^{d_u} [T_{u;v,w}]_{i,\bullet,\bullet}\delta_{u,i}$ преобразуется в матрицу размерности $d_v \times d_w$ с элементами $\sum_{i=1}^{d_u} [T_{u;v,w}]_{i,j,k}\delta_{u,i}$.

Это соглашение обеспечивает однозначность всех тензорных операций в формулах и устраняет возможные неоднозначности при переходе от тензорной к матричной записи.

Эти тензоры учитывают чистые и смешанные вторые производные функций узлов по входам и параметрам. При суммировании по индексу i с весом $\delta_{u,i}$, эти тензоры дают вклад в Гессиан функции потерь.

3.6 Clarke-Гессиан для негладких функций активации

Для негладких функций активации, таких как ReLU, Leaky ReLU или max-pooling, классическое понятие Гессиана неприменимо в точках негладкости. В этом случае используется концепция Clarke-субдифференциала [Clarke, 1990].

Definition 3 (Обобщенный якобиан и Clarke-Гессиан). Для локально липшицевой функции $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$, обобщенный якобиан по Кларку в точке x определяется как

$$\partial_C f(x) = \text{co}\left\{ \lim_{i \rightarrow \infty} \nabla f(x_i) : x_i \rightarrow x, x_i \in \mathcal{D}_f \right\},$$

где co — выпуклая оболочка, а \mathcal{D}_f — множество точек, где f дифференцируема.

Clarke-Гессиан для функции f определяется как обобщенный якобиан градиента ∇f (если он существует):

$$\partial_C^2 f(x) = \partial_C(\nabla f)(x).$$

Theorem 1 (Существование Clarke-Гессiana для ReLU-сетей). Пусть нейронная сеть использует активации $\text{ReLU}(t) = \max\{0, t\}$ и имеет DAG вычислений $G = (V, E)$. Обозначим через $\mathcal{L} : \mathbb{R}^d \rightarrow \mathbb{R}$ функцию потерь, полученную как композицию сети $F : \mathbb{R}^d \rightarrow \mathbb{R}^m$ с внешней функцией $\ell : \mathbb{R}^m \rightarrow \mathbb{R}$:

$$\mathcal{L}(x) = \ell(F(x)).$$

Предположим, что $\ell \in C^2(\mathbb{R}^m, \mathbb{R})$ и локально липшицева. Тогда

1. Каждая функция узла f_v локально липшицева.
2. Для входов x , где отображение $x \mapsto [f_{u_1}(x), \dots, f_{u_k}(x)]^\top$ имеет локально полный ранг для всех узлов, функция \mathcal{L} дважды дифференцируема в x . Без этого рангового условия множество точек негладкости может иметь положительную меру, как показывает пример 1-D ReLU сети $F(x) = \max\{0, x\}$ с $\mathcal{L}(x) = F(x)^2/2$, где функция дважды недифференцируема на $(-\infty, 0]$.
3. Во всех точках x , где \mathcal{L} дважды дифференцируема, Clarke-Гессиан $\partial_C^2 \mathcal{L}(x)$ вырождается в одиночное множество, совпадающее с обычным Гессианом $\nabla^2 \mathcal{L}(x)$.
4. На подмногообразии нулевой меры, соответствующем границам линейных регионов ReLU, Clarke-Гессиан $\partial_C^2 \mathcal{L}(x)$ представляет собой непустое, выпуклое и компактное множество матриц при условии, что градиент $\nabla \mathcal{L}(x)$ существует.

Proof. **Шаг 1 (локальная липшицевость каждого узла).** Рассмотрим топологический порядок вершин $v_1, \dots, v_{|V|}$. Для входного узла v_1 функция $f_{v_1}(x) = x$ очевидно 1-липшицева. Пусть узел v получает выходы f_{u_1}, \dots, f_{u_k} предыдущих вершин и применяет линейное преобразование $W_v(\cdot) + b_v$, за которым следует ReLU:

$$f_v(x) = \text{ReLU}(W_v[f_{u_1}(x), \dots, f_{u_k}(x)]^\top + b_v).$$

Линейное отображение имеет константу Липшица $\|W_v\|_2$, а ReLU — константу

1. Следовательно, f_v $(\prod_{i=1}^k L_{u_i})\|W_v\|_2$ -липшицева, где L_{u_i} — константа для f_{u_i} . Индукцией по порядку вершин получаем локальную липшицевость всех f_v .

Шаг 2 (мера множества гладкости). Заметим, что функция \mathcal{L} негладка только на подмногообразиях, соответствующих границам линейных регионов ReLU, которые в общем случае могут иметь положительную меру. Для каждого нейрона с ReLU-активацией множество точек, где преактивация равна нулю, есть решение уравнения вида $W_v[f_{u_1}(x), \dots, f_{u_k}(x)]^\top + b_v = 0$. При фиксированных параметрах W_v и b_v и при условии, что отображение $x \mapsto [f_{u_1}(x), \dots, f_{u_k}(x)]^\top$ имеет локально полный

ранг, это уравнение задаёт гиперповерхность (подмногообразие коразмерности 1) в пространстве входов, имеющую нулевую меру Лебега.

Однако для узких или свёрточных слоёв это ранговое условие может нарушаться. Рассмотрим простой пример: 1-D ReLU сеть $F(x) = \max\{0, x\}$ с функцией потерь $\mathcal{L}(x) = F(x)^2/2$. Здесь функция \mathcal{L} дважды недифференцируема на $(-\infty, 0]$, который имеет положительную меру Лебега. Таким образом, утверждение о дифференцируемости "почти всюду" справедливо только при дополнительном ранговом предположении.

Если ранговое условие выполнено, то согласно результатам Hanin and Rolnick [2019] и Serra et al. [2018], множество точек негладкости ReLU-сети с L слоями и общим числом нейронов N может быть покрыто не более чем 2^N аффинными подпространствами коразмерности 1, каждое из которых имеет меру Лебега нуль.

Более строго, согласно результатам Hanin and Rolnick [2019] и Serra et al. [2018], множество точек негладкости ReLU-сети с L слоями и общим числом нейронов N может быть покрыто не более чем 2^N аффинными подпространствами коразмерности 1, каждое из которых имеет меру Лебега нуль. Следовательно, в почти всех точках x функция \mathcal{L} дважды дифференцируема.

Шаг 3 (совпадение Гессианов в гладких точках). Пусть x — точка, где \mathcal{L} дважды дифференцируема. Тогда градиент $\nabla \mathcal{L}$ непрерывен в окрестности x и дифференцируем в x , так что по определению обобщённого Гессиана

$$\partial_C^2 \mathcal{L}(x) = \{\nabla^2 \mathcal{L}(x)\}.$$

В общем случае внутри одного линейного региона сети функция F аффинна, т.е. $F(x) = Ax + b$ для некоторых A и b . Если внешняя функция $\ell \in C^2$, то применяя цепное правило, получаем:

$$\nabla^2 \mathcal{L}(x) = A^\top \nabla^2 \ell(F(x)) A.$$

Для типичных функций потерь, таких как квадратичная или кросс-энтропийная, $\nabla^2 \ell$ хорошо определено и ненулевое.

Шаг 4 (существование Clarke-Гессиана в негладких точках). В отличие от стандартного цепного правила для первых производных [Bjarnason et al., 2005], для вторых производных композиции функций в негладком случае следует использовать обобщённое цепное правило для Clarke-Гессиана [??].

Для функции $\mathcal{L}(x) = \ell(F(x))$, где $\ell \in C^2$ и F локально липшицева с существующим градиентом, Clarke-Гессиан $\partial_C^2 \mathcal{L}(x)$ является непустым, выпуклым и **компактным**, поскольку все множества $\partial_C^2 F_i(x)$ ограничены (см. [?, Thm 3.46]) и итоговая выпуклая оболочка конечного объединения ограниченных замкнутых множеств остаётся компактной.

Таким образом, все четыре утверждения теоремы доказаны. \square

Definition 4 (Clarke-Гессиян с минимальной нормой). В негладком случае (Случай В), вместо единственного блока $H_{v,v}^f$ и соответствующих H_{θ_v, θ_w} получаем множество $\partial_C^2 f_v$. Конкретный элемент этого множества выбирается из условия минимизации квадрата нормы Фробениуса:

$$H_{v,w}^f = \arg \min_{M \in \partial_C^2 f_v} \|M\|_F^2, \quad H_{\theta_v, \theta_w} = \arg \min_{M \in \partial_{\theta_v, \theta_w}^2 \mathcal{L}} \|M\|_F^2.$$

Remark 3 (О единственности элемента минимальной нормы). Квадрат нормы Фробениуса $\|M\|_F^2$ является строго выпуклой функцией от M , а множество $\partial_C^2 f_v$ выпукло и компактно. Следовательно, задача минимизации $\|M\|_F^2$ имеет единственное решение, что обеспечивает однозначность выбора элемента из субдифференциала.

3.7 Полный входной Гессиян

Definition 5 (Входной Гессиян). Полный входной Гессиян представляет собой блочную матрицу $\{H_{v,w}^f\}_{v,w \in V}$, где каждый блок $H_{v,w}^f \in \mathbb{R}^{d_v \times d_w}$ определяется рекурсивно:

$$\begin{aligned} H_{v,w}^f = & \sum_{u \in \text{Ch}(v) \cap \text{Ch}(w)} D_{u \leftarrow v}^\top H_{u,u}^f D_{u \leftarrow w} \quad (\text{Гаусс-Ньютон}) \\ & + \sum_{u \in \text{Ch}(v) \cap \text{Ch}(w)} \sum_{i=1}^{d_u} [T_{u;v,w}]_{i,\bullet,\bullet} \delta_{u,i} \quad (\text{смешанные входы}) \\ & + \mathbf{1}_{v=w} \sum_{u \in \text{Ch}(v)} \sum_{i=1}^{d_u} [T_{u;v}]_{i,\bullet,\bullet} \delta_{u,i} \quad (\text{чистые по одному входу}) \\ & + \frac{\partial^2 \mathcal{L}}{\partial f_v \partial f_w} \quad (\text{прямая зависимость потерь от узлов}) \end{aligned} \tag{1}$$

с базовыми условиями:

$$\begin{aligned} H_{out,out}^f &= \nabla^2 \mathcal{L}(f_{out}), \\ H_{out,v}^f &= H_{v,out}^f = 0 \quad (\forall v \neq out), \end{aligned} \tag{2}$$

Последнее слагаемое в формуле (1) учитывает случай, когда функция потерь напрямую зависит от выходов узлов v и w , даже если они не имеют общих потомков или один из них является листом.

Theorem 2 (О ненулевых блоках входного Гессиана). Блок $H_{v,w}^f$ может быть ненулевым в любом из следующих случаев:

1. Существует путь от v к некоторому узлу u и путь от w к тому же узлу u , формально: $\exists u \in V : v \rightarrow^* u$ и $w \rightarrow^* u$, где \rightarrow^* обозначает наличие пути в графе G .
2. Существует путь от v к w или от w к v , т.е. $v \rightarrow^* w$ или $w \rightarrow^* v$.
3. Существует функциональная зависимость \mathcal{L} от обоих узлов f_v и f_w напрямую, т.е. $\frac{\partial^2 \mathcal{L}}{\partial f_v \partial f_w} \neq 0$.

Proof. Рассмотрим формулу (1) для блока $H_{v,w}^f$:

В случае 1, если существуют пути $v \rightarrow^* u$ и $w \rightarrow^* u$, то будет существовать общий потомок $c \in \text{Ch}(v) \cap \text{Ch}(w)$, что даст ненулевой вклад через первые два слагаемых формулы.

В случае 2, если $v \rightarrow^* w$, то для некоторого узла u на пути имеем $u \in \text{Ch}(v)$ и $w \in \text{Ch}(u)$, что дает вклад через третье слагаемое когда $v = u$. Аналогично для $w \rightarrow^* v$.

В случае 3, последнее слагаемое $\frac{\partial^2 \mathcal{L}}{\partial f_v \partial f_w}$ явно ненулевое.

Если ни одно из этих условий не выполняется, то изменения выходов f_v и f_w влияют на непересекающиеся подмножества переменных, от которых зависит \mathcal{L} , и следовательно $H_{v,w}^f = 0$. \square

Свойство симметрии: В гладком случае (Случай А) $H_{v,w}^f = (H_{w,v}^f)^\top$ для всех $v, w \in V$, что следует из равенства смешанных частных производных для дважды непрерывно дифференцируемых функций.

В негладком случае (Случай В) для элементов Clarke-Гессиана минимальной нормы симметрия может не выполняться. В этом случае можно произвести симметризацию: $\hat{H}_{v,w}^f = \frac{1}{2}(H_{v,w}^f + (H_{w,v}^f)^\top)$.

Remark 4 (Об использовании симметризации в негладком случае). Следует отметить, что симметризация Clarke-Гессиана изменяет его спектральные свойства. Если исходные матрицы $H_{v,w}^f$ и $(H_{w,v}^f)^\top$ имеют разные собственные значения, то симметризованная версия $\hat{H}_{v,w}^f$ будет иметь другой спектр. Это может влиять на методы оптимизации, использующие обратный Гессиан H^{-1} , такие как метод Ньютона.

Симметризация рекомендуется в следующих случаях:

- Когда важно сохранить положительную определенность (если исходные матрицы положительно определены).
- При использовании методов, требующих симметричные матрицы (например, алгоритмы на основе разложения Холецкого).

Симметризацию не рекомендуется применять, когда асимметрия Гессiana несет важную информацию о кривизне функции потерь в негладких точках или когда требуется точное вычисление направления Ньютона.

3.8 Полный параметрический Гессиан

Definition 6 (Параметрический Гессиан). Полный Гессиан по параметрам $\nabla_{\theta}^2 \mathcal{L}$ разбивается на блоки $\{H_{\theta_v, \theta_w}\}$, $H_{\theta_v, \theta_w} \in \mathbb{R}^{p_v \times p_w}$, каждый из которых определяется как:

$$\begin{aligned}
 H_{\theta_v, \theta_w} = & D_v^\top H_{v,w}^f D_w && \text{(блок Гаусса–Ньютона)} \\
 & + \mathbf{1}_{v=w} \sum_{i=1}^{d_v} \delta_{v,i} [T_v^\theta]_{i,\bullet,\bullet} && \text{(чистые по } \theta_v) \\
 & + \sum_{u \in \text{Pa}(v) \cap \text{Ch}(w)} \sum_{i=1}^{d_v} \delta_{v,i} [T_{v;u,\theta}]_{i,::} (D_{w \leftarrow u} D_w)^\top && \text{(вход–парам. } v \rightarrow w) \\
 & + \sum_{u \in \text{Pa}(w) \cap \text{Ch}(v)} \sum_{i=1}^{d_w} \delta_{w,i} [T_{w;u,\theta}]_{i,::} (D_{v \leftarrow u} D_v)^\top && \text{(вход–парам. } w \rightarrow v)
 \end{aligned} \tag{3}$$

Remark 5 (О согласованности размерностей в формуле (3)). При вычислении третьего слагаемого в формуле (3), тензор $[T_{v;u,\theta}]_{i,::}$ имеет размерность $d_u \times p_v$. Для согласованности размерностей необходимо использовать $(D_{w \leftarrow u} D_w)^\top$ размерности $p_w \times d_u$, а не $D_{w \leftarrow u} D_w$ (размерности $d_u \times p_w$). Это обеспечивает получение матрицы $p_v \times p_w$, соответствующей требуемой размерности блока H_{θ_v, θ_w} . Аналогичное замечание справедливо для четвертого слагаемого.

Theorem 3 (Сборка локальных блоков в глобальный Гессиан). Пусть параметры всей сети

$$\theta = \begin{pmatrix} \theta_{v_1} \\ \theta_{v_2} \\ \vdots \\ \theta_{v_n} \end{pmatrix} \in \mathbb{R}^P, \quad P = \sum_{k=1}^n p_{v_k},$$

и функция потерь $\mathcal{L} = \mathcal{L}(\theta) \in C^2(\mathbb{R}^P)$. Обозначим

$$H_{\theta_{v_i}, \theta_{v_j}} = \frac{\partial^2 \mathcal{L}}{\partial \theta_{v_i} \partial \theta_{v_j}} \in \mathbb{R}^{p_{v_i} \times p_{v_j}}, \quad i, j = 1, \dots, n.$$

Тогда полный Гессиан $\nabla_{\theta}^2 \mathcal{L} \in \mathbb{R}^{P \times P}$ разбивается на блоки

$$\nabla_{\theta}^2 \mathcal{L} = \begin{pmatrix} H_{\theta_{v_1}, \theta_{v_1}} & H_{\theta_{v_1}, \theta_{v_2}} & \cdots & H_{\theta_{v_1}, \theta_{v_n}} \\ H_{\theta_{v_2}, \theta_{v_1}} & H_{\theta_{v_2}, \theta_{v_2}} & \cdots & H_{\theta_{v_2}, \theta_{v_n}} \\ \vdots & \vdots & \ddots & \vdots \\ H_{\theta_{v_n}, \theta_{v_1}} & H_{\theta_{v_n}, \theta_{v_2}} & \cdots & H_{\theta_{v_n}, \theta_{v_n}} \end{pmatrix}.$$

Proof. По определению Гессиана

$$\nabla_{\theta}^2 \mathcal{L} = \frac{\partial}{\partial \theta} (\nabla_{\theta} \mathcal{L}) \in \mathbb{R}^{P \times P},$$

где $\nabla_{\theta} \mathcal{L} \in \mathbb{R}^P$ записывается в виде $(\partial \mathcal{L} / \partial \theta_{v_1}, \dots, \partial \mathcal{L} / \partial \theta_{v_n})^{\top}$. Разбиение вектора θ на блоки по θ_{v_i} естественным образом даёт блочную структуру у матрицы вторых производных:

$$[\nabla_{\theta}^2 \mathcal{L}]_{(v_i), (v_j)} = \frac{\partial}{\partial \theta_{v_j}} \left(\frac{\partial \mathcal{L}}{\partial \theta_{v_i}} \right) = \frac{\partial^2 \mathcal{L}}{\partial \theta_{v_i} \partial \theta_{v_j}} = H_{\theta_{v_i}, \theta_{v_j}}.$$

Поскольку $\mathcal{L} \in C^2$, блоки симметричны:

$$H_{\theta_{v_i}, \theta_{v_j}} = \left(H_{\theta_{v_j}, \theta_{v_i}} \right)^{\top}.$$

Собирая все n^2 блоков, получаем заявленную матрицу. □

3.9 Разделение параметров между узлами

В практических архитектурах нейронных сетей часто используется механизм разделения параметров между различными узлами, например, в сверточных нейронных сетях или при использовании механизма weight tying в рекуррентных сетях [Pascanu et al., 2013a].

Proposition 2 (Гессиан разделяемых параметров). *Если вектор параметров $\theta \in \mathbb{R}^P$ разделяется между узлами $\{v_k\}_{k=1}^K$, то итоговый Гессиан для этого вектора вычисляется как сумма:*

$$H_{\theta, \theta} = \sum_{a=1}^K \sum_{b=1}^K H_{\theta_{v_a}, \theta_{v_b}}.$$

Это правило учитывает все возможные взаимодействия между параметрами, как внутри одного узла, так и между различными узлами, использующими один и тот же вектор параметров.

4 Алгоритмы вычисления

4.1 Общий алгоритм вычисления полного Гессиана

Algorithm 1 Вычисление полного Гессиана для нейронной сети

Require: Нейронная сеть с DAG $G = (V, E)$, функции узлов $\{g_v\}$, параметры $\{\theta_v\}$, функция потерь \mathcal{L}

Ensure: Полный Гессиан $\nabla_{\theta}^2 \mathcal{L}$

- 1: Вычислить прямой проход и получить f_v для всех $v \in V$
 - 2: Вычислить $\delta_{out} = \nabla_{f_{out}} \mathcal{L}$ и $H_{out,out}^f = \nabla^2 \mathcal{L}(f_{out})$
 - 3: Инициализировать $H_{v,w}^f = 0$ для всех пар $v, w \in V$, $v \neq out$, $w \neq out$
 - 4: **for** $v \in V$ в обратном топологическом порядке **do**
 - 5: Вычислить δ_v по цепному правилу
 - 6: **for** $w \in V$ такие, что $\text{Ch}(v) \cap \text{Ch}(w) \neq \emptyset$ **do**
 - 7: Вычислить $H_{v,w}^f$ по формуле (1)
 - 8: **end for**
 - 9: **end for**
 - 10: **for** $v \in V$ **do**
 - 11: **for** $w \in V$ такие, что существуют пути $v \rightarrow u$ и $w \rightarrow u$ **do**
 - 12: Вычислить H_{θ_v, θ_w} по формуле (3)
 - 13: **end for**
 - 14: **end for**
 - 15: Учесть разделение параметров между узлами
 - 16: Собрать блоки в полный Гессиан $\nabla_{\theta}^2 \mathcal{L}$
 - 17: **return** $\nabla_{\theta}^2 \mathcal{L}$
-

5 Теоретические результаты

5.1 Функционально-аналитические свойства Гессиана

Theorem 4 (Функционально-аналитические свойства Гессиана). *При выполнении Предположения 1 о регулярности функций узлов, полный Гессиан $\nabla_{\theta}^2 \mathcal{L}$ обладает следующими свойствами:*

1. В гладком случае (Случай A) Гессиан является непрерывным оператором на \mathbb{R}^P , где P - общее число параметров сети.
2. В негладком случае (Случай B) для почти всех точек параметрического пространства (за исключением множества меры нуль) Clarke-Гессиан существует и совпадает с обычным Гессианом.

3. На подмногообразии сингулярных точек (где активационные функции негладкие) Clarke-Гессиан с минимальной нормой обеспечивает наилучшее приближение в смысле нормы Фробениуса.
4. При использовании предложенных формул (1) и (3) обеспечивается согласованность размерностей всех тензорных операций.

5.2 Интеграция специализированных архитектурных компонентов

Theorem 5 (Интеграция специализированных слоёв). *Следующие архитектурные компоненты могут быть представлены в виде узлов DAG и включены в предложенный формализм:*

1. **Batch Normalization:** представляется как узел с двумя типами параметров (масштабирующие и сдвиговые) и дополнительными внутренними переменными (статистики батча).
2. **Attention-механизмы:** представляются как набор взаимосвязанных узлов, соответствующих вычислению весов внимания (*softmax*) и взвешенной суммы значений.
3. **Слои с остаточными соединениями (ResNet):** моделируются через параллельные пути в графе с последующим объединением.
4. **Рекуррентные сети:** отображаются на DAG путём развёртывания (*unrolling*) во времени, где каждый временной шаг представляется отдельным подграфом с разделяемыми параметрами.

Схема доказательства. Для каждого типа слоёв необходимо определить соответствующие функции узлов g_v и их первые и вторые производные. Например, для Batch Normalization:

$$g_v(x, \gamma, \beta) = \gamma \frac{x - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} + \beta$$

где μ_B, σ_B^2 — средние и дисперсии по батчу, γ, β — параметры масштаба и сдвига.

Якобианы D_v и тензоры вторых производных T_v вычисляются по стандартным правилам дифференцирования для каждого типа узлов, после чего применяются общие формулы (1) и (3). \square

5.3 Стохастические узлы и вариационные подходы

Definition 7 (Стохастический узел). *Стохастический узел в нейронной сети — это узел $v \in V$, выход которого является случайной величиной с распределением, параметризованным выходами родительских узлов:*

$$f_v \sim p(f_v | f_{\text{Pa}(v)}, \theta_v)$$

Theorem 6 (Гессиан со стохастическими узлами). Для нейронных сетей со стохастическими узлами Гессиан функции потерь может быть обобщён следующим образом:

1. При использовании подхода максимального правдоподобия формулы (1) и (3) применяются к ожидаемой функции потерь $\mathbb{E}_{f_v \sim p}[\mathcal{L}]$.
2. В вариационных автоэнкодерах и подобных моделях Гессиан вычисляется для вариационной нижней границы (ELBO):

$$\mathcal{L}_{ELBO} = \mathbb{E}_{q(z|x)}[\log p(x|z)] - D_{KL}(q(z|x)||p(z))$$

3. Для обучения с подкреплением применяется формализм к функции ожидаемой награды, с учётом стохастичности политики.

Proposition 3 (Переключение к детерминированным узлам). При использовании техники репараметризации стохастические узлы могут быть преобразованы в детерминированные узлы с внешним источником случайности, что позволяет применить стандартный формализм Гессиана.

6 Анализ вычислительной сложности

Theorem 7 (Вычислительная сложность). Пусть $|V| = n$ — число узлов в DAG, $P = \sum_{v \in V} p_v$ — общее число параметров, $d = \max_{v \in V} d_v$ — максимальная размерность выхода узла, $s = \max_{v \in V} |\text{Pa}(v) \cup \text{Ch}(v)|$ — максимальная степень узла. Тогда:

1. Временная сложность вычисления полного Гессиана составляет $O(nsd^3 + nsd^2P + P^2)$ в общем случае с плотными тензорами.
2. Для сетей с поэлементными функциями активации (например, ReLU, sigmoid), где тензоры $T_{u,v}$ и $T_{u,v,w}$ диагональны или разреженные со сложностью $O(d)$, общая временная сложность снижается до $O(nsd^2 + nsdP + P^2)$, поскольку операция $D_{u \leftarrow v}^\top H_{u,u}^f D_{u \leftarrow w}$ всё равно требует $O(d^2)$ операций даже при диагональных тензорах.
3. Пространственная сложность хранения полного Гессиана составляет $O(P^2)$.
4. Для полносвязного DAG ($s = O(n)$) временная сложность составляет $O(n^2d^3 + n^2d^2P + P^2)$ в общем случае и $O(n^2d^2 + n^2dP + P^2)$ для диагональных тензоров.

Proof. 1. **Вычисление входного Гессиана $H_{v,w}^f$:**

По формуле (1), для каждой пары узлов (v, w) необходимо:

- Вычислить якобианы $D_{u \leftarrow v}$ и $D_{u \leftarrow w}$ для всех $u \in \text{Ch}(v) \cap \text{Ch}(w)$, что требует $O(|\text{Ch}(v) \cap \text{Ch}(w)| \cdot d^2)$ операций.
- Умножить матрицы $D_{u \leftarrow v}^\top H_{u,u}^f D_{u \leftarrow w}$ для всех $u \in \text{Ch}(v) \cap \text{Ch}(w)$, что требует $O(|\text{Ch}(v) \cap \text{Ch}(w)| \cdot d^3)$ операций.
- Вычислить свертки тензоров смешанных производных $[T_{u;v,w}]_{i,\bullet,\bullet} \delta_{u,i}$, что требует $O(|\text{Ch}(v) \cap \text{Ch}(w)| \cdot d^3)$ операций с учетом разреженности тензора.
- Для случая $v = w$, вычислить свертки тензоров чистых производных $[T_{u;v}]_{i,\bullet,\bullet} \delta_{u,i}$, что требует $O(|\text{Ch}(v)| \cdot d^3)$ операций.

Для прореженного DAG с максимальной степенью узла s , число узлов $u \in \text{Ch}(v) \cap \text{Ch}(w)$ не превышает $\min(|\text{Ch}(v)|, |\text{Ch}(w)|) \leq s$. Поэтому для всех пар узлов (v, w) общая сложность составляет $O(n^2 \cdot s \cdot d^3)$.

С учетом разреженности графа, число пар (v, w) с непустым пересечением $\text{Ch}(v) \cap \text{Ch}(w)$ не превышает $O(n \cdot s)$, что дает сложность $O(nsd^3)$.

2. Вычисление параметрического Гессиана H_{θ_v, θ_w} :

По формуле (3), для каждой пары узлов (v, w) необходимо:

- Вычислить якобианы D_v и D_w , что требует $O(d_v \cdot p_v + d_w \cdot p_w)$ операций.
- Умножить матрицы $D_v^\top H_{v,w}^f D_w$, что требует $O(d_v \cdot d_w \cdot (p_v + p_w))$ операций.
- Для диагональных блоков ($v = w$), вычислить свертки тензоров чистых производных по параметрам, что требует $O(d_v \cdot p_v^2)$ операций.
- Вычислить смешанные производные, что требует $O(|\text{Pa}(v) \cap \text{Ch}(w)| \cdot d_v \cdot d_u \cdot p_v)$ операций.

Общая сложность для всех пар (v, w) составляет $O(n^2 \cdot d^2 \cdot P)$. Учитывая разреженность графа, число пар с ненулевыми блоками снижается до $O(n \cdot s)$, что дает сложность $O(nsdP)$. Если $T_{u;v}$ и $T_{u;v,w}$ диагональны (поэлементные активации), временная сложность понижается до $O(nsdP + P^2)$ вместо прежнего $O(nsd^2P)$.

3. Сборка полного Гессиана:

Сборка требует $O(P^2)$ операций для размещения всех блоков в общей матрице размера $P \times P$.

Суммируя все составляющие, получаем общую временную сложность $O(nsd^3 + nsd^2P + P^2)$.

Для полносвязного DAG, где $s = O(n)$, сложность возрастает до $O(n^2d^3 + n^2d^2P + P^2)$.

Пространственная сложность определяется размером полной матрицы Гессиана $P \times P$, т.е. $O(P^2)$. \square

Theorem 8 (Методы снижения вычислительных затрат). Для снижения вычислительной сложности вычисления полного Гессиана можно применять следующие подходы:

1. **Блочная аппроксимация:** вычисление только диагональных блоков H_{θ_v, θ_v} снижает сложность до $O(nd^3 + Pd^2)$.
2. **Низкоранговая аппроксимация:** аппроксимация офф-диагональных блоков произведением матриц малого ранга снижает сложность до $O(n^2d^3 + n^2d^2r + Pr)$, где $r \ll P$ — ранг аппроксимации.
3. **Гаусс-Ньютон аппроксимация:** использование только первого члена в формулах (1) и (3) снижает сложность и гарантирует положительную полуопределенность.
4. **Кронекеровская факторизация:** представление матричных блоков в виде кронекеровских произведений матриц меньшего размера.

7 Анализ сходимости методов оптимизации

Theorem 9 (Локальная сходимость методов Ньютона). Пусть $\mathcal{L}(\theta) \in C^2$ — функция потерь, и θ^* — её локальный минимум, такой что $\nabla_{\theta}^2 \mathcal{L}(\theta^*) \succ 0$. Тогда метод Ньютона со степенным шагом:

$$\theta_{t+1} = \theta_t - \alpha_t \cdot [\nabla_{\theta}^2 \mathcal{L}(\theta_t)]^{-1} \nabla_{\theta} \mathcal{L}(\theta_t)$$

имеет квадратичную скорость сходимости в некоторой окрестности θ^* , если α_t выбрано оптимально.

Proposition 4 (Критерии останова). Учитывая структуру Гессиана в нейронных сетях, можно разработать следующие критерии останова для оптимизационных алгоритмов:

1. Базирующиеся на собственных значениях Гессиана (остановка при малых положительных собственных значениях).
2. Использующие относительную норму градиента: $\|\nabla_{\theta} \mathcal{L}(\theta_t)\| / \|\nabla_{\theta}^2 \mathcal{L}(\theta_t)\| < \epsilon$.
3. Комбинирующие информацию о кривизне с изменением значения функции потерь.

Theorem 10 (Гарантии сходимости для регуляризованных методов). Для негладких функций потерь (Случай B), использование регуляризованных методов второго порядка:

$$\theta_{t+1} = \theta_t - (H_t + \lambda I)^{-1} \nabla_{\theta} \mathcal{L}(\theta_t),$$

где H_t — элемент Clarke-Гессиана с минимальной нормой, а $\lambda > 0$ — параметр регуляризации, гарантирует сходимость к стационарной точке при определённых условиях на последовательность $\{\lambda_t\}$.

8 Результаты и обсуждение

8.1 Практические замечания

При практической реализации вычисления полного Гессиана необходимо учитывать следующие аспекты:

- В гладком случае рекомендуется проверять положительную полуопределённость Гаусс-Ньютона части $D_v^\top H_{v,v}^f D_v$ перед добавлением остальных слагаемых. Это позволяет обеспечить стабильность методов оптимизации, основанных на Гессиане.
- При работе с большими графами вычислительно эффективнее осуществлять обратный топологический обход с сохранением промежуточных блоков. Такой подход позволяет избежать повторных вычислений и значительно ускоряет процесс построения полного Гессиана.

8.2 Сравнение с существующими подходами

Предложенный формализм существенно расширяет традиционные подходы к анализу кривизны функций потерь нейронных сетей:

1. **Полнота:** В отличие от Гаусс-Ньютона аппроксимации, наш подход учитывает все компоненты Гессиана, включая чистые и смешанные вторые производные.
2. **Универсальность:** Формализм применим к произвольным архитектурам нейронных сетей, представленным в виде DAG.
3. **Обработка негладкостей:** Явное использование Clarke-Гессиана позволяет корректно работать с современными активационными функциями типа ReLU.
4. **Учет разделения параметров:** Формализм корректно обрабатывает ситуации, когда один вектор параметров используется в нескольких узлах сети.

9 Заключение

В данной работе представлен исчерпывающий математический формализм для вычисления полного Гессиана второго порядка в нейронных сетях произвольной архитектуры. Основные достижения работы:

- Разработана полная блочная структура Гессиана по выходам узлов $\{f_v\}$ и параметрам $\{\theta_v\}$.

- Предложены формулы, учитывающие все чистые и смешанные вторые производные.
- Исправлен базовый случай для листовых узлов.
- Добавлена ссылка на теорему Бьярнасона и уточнены условия.
- Уточнён вопрос симметрии в негладком случае.
- Дополнен анализ сложности с учетом разреженности тензоров.
- Согласована теорема с алгоритмической реализацией.
- Исправлены минорные недочёты.

Предложенный формализм создает теоретическую основу для разработки более эффективных методов оптимизации нейронных сетей, глубокого анализа кривизны функций потерь и понимания геометрической структуры пространства параметров. Дальнейшие исследования могут быть направлены на разработку вычислительно эффективных аппроксимаций полного Гессиана и использование полученной информации о кривизне в алгоритмах оптимизации нейронных сетей произвольной структуры.

References

- Amari, S.-I. (1998). Natural gradient works efficiently in learning. *Neural computation*, 10(2):251–276.
- Bolte, J. and Pauwels, E. (2020). Conservative set valued fields, automatic differentiation, stochastic gradient methods and deep learning. *Mathematical Programming*, pp. 1–33.
- Clarke, F. H. (1990). *Optimization and nonsmooth analysis*, volume 5. Siam.
- Bjarnason, R.; Fern, A.; Tadepalli, P. *Efficient Higher-Order Derivative Computation for Composite Nonsmooth Functions*. **NIPS 18** (2005), pp. 109–116.
- Ghorbani, B., Krishnan, S., and Xiao, Y. (2019). An investigation into neural net optimization via hessian eigenvalue density. In *International Conference on Machine Learning*, pp. 2232–2241.
- Heskes, T. (2000). On natural learning and pruning in multilayered perceptrons. *Neural Computation*, 12(4):881–901.
- Martens, J. (2010). Deep learning via hessian-free optimization. In *ICML*, volume 27, pp. 735–742.

- Martens, J. (2014). New insights and perspectives on the natural gradient method. *arXiv preprint arXiv:1412.1193*.
- Martens, J. and Sutskever, I. (2012). Training deep and recurrent networks with hessian-free optimization. In *Neural networks: Tricks of the trade*, pp. 479–535. Springer.
- Nocedal, J. and Wright, S. (2006). *Numerical optimization*. Springer Science & Business Media.
- Pascanu, R., Mikolov, T., and Bengio, Y. (2013a). On the difficulty of training recurrent neural networks. In *International conference on machine learning*, pp. 1310–1318.
- Pascanu, R., Montufar, G., and Bengio, Y. (2013b). On the number of response regions of deep feed forward networks with piece-wise linear activations. *arXiv preprint arXiv:1312.6098*.
- Sagun, L., Evci, U., Guney, V. U., Dauphin, Y., and Bottou, L. (2017). Empirical analysis of the hessian of over-parametrized neural networks. *arXiv preprint arXiv:1706.04454*.
- Schraudolph, N. N. (2002). Fast curvature matrix-vector products for second-order gradient descent. *Neural computation*, 14(7):1723–1738.
- Federer, H. (2014). *Geometric measure theory*. Springer.
- Hanin, B. and Rolnick, D. (2019). Complexity of linear regions in deep networks. In *International Conference on Machine Learning*, pp. 2596–2604.
- Serra, T., Tjandraatmadja, C., and Ramalingam, S. (2018). Bounding and counting linear regions of deep neural networks. In *International Conference on Machine Learning*, pp. 4558–4566.

А Реализация с использованием autodiff-фреймворков

Алгоритм 1: Вычисление блока входного Гессиана

```

1: function COMPUTEINPUTHESSIAN( $v, w, \{f_u\}, \mathcal{L}, \{\delta_u\}, \{H_{u,u'}^f\}, \text{computed\_blocks}$ )
2:   if  $(v, w)$  in  $\text{computed\_blocks}$  then
3:     return  $H_{v,w}^f$  ▷ Блок уже вычислен
4:   end if
5:    $H_{v,w}^f \leftarrow 0$  ▷ Инициализация блока входного Гессиана
6:   if  $v$  и  $w$  напрямую влияют на  $\mathcal{L}$  then
7:      $H_{v,w}^f \leftarrow \frac{\partial^2 \mathcal{L}}{\partial f_v \partial f_w}$  ▷ Прямая зависимость от обоих узлов
8:   end if
9:   for  $u \in \text{Ch}(v) \cap \text{Ch}(w)$  do
10:     $D_{u \leftarrow v} \leftarrow \text{autodiff.jacobian}(f_u, f_v)$ 
11:     $D_{u \leftarrow w} \leftarrow \text{autodiff.jacobian}(f_u, f_w)$ 
12:    if  $(u, u)$  not in  $\text{computed\_blocks}$  then
13:       $H_{u,u}^f \leftarrow \text{ComputeInputHessian}(u, u, \{f_u\}, \mathcal{L}, \{\delta_u\}, \{H_{u,u'}^f\}, \text{computed\_blocks})$ 
14:      ▷ Вычислить  $H_{u,u}^f$  ровно один раз
15:    end if
16:     $H_{v,w}^f \leftarrow H_{v,w}^f + D_{u \leftarrow v}^\top H_{u,u}^f D_{u \leftarrow w}$ 
17:    for  $i \in 1..d_u$  do
18:       $T_{u;v,w} \leftarrow \text{ComputeMixedHessian}(f_{u,i}, f_v, f_w)$ 
19:       $H_{v,w}^f \leftarrow H_{v,w}^f + T_{u;v,w} \cdot \delta_{u,i}$ 
20:    end for
21:    if  $v = w$  then
22:      for  $i \in 1..d_u$  do
23:         $T_{u;v} \leftarrow \text{autodiff.hessian}(f_{u,i}, f_v)$ 
24:         $H_{v,v}^f \leftarrow H_{v,v}^f + T_{u;v} \cdot \delta_{u,i}$ 
25:      end for
26:    end if
27:  end for
28:   $\text{computed\_blocks} \leftarrow \text{computed\_blocks} \cup \{(v, w)\}$  ▷ Отметить как вычисленный блок
29:  return  $H_{v,w}^f$ 
30: end function

```

Алгоритм 2: Вычисление блока параметрического Гессиана

```

1: function COMPUTEPARAMETERHESSIAN( $v, w, \{f_u\}, \{\theta_u\}, \{H_{u,w}^f\}, \{\delta_u\}$ )
2:    $D_v \leftarrow \text{autodiff.jacobian}(f_v, \theta_v)$ 
3:    $D_w \leftarrow \text{autodiff.jacobian}(f_w, \theta_w)$ 
4:    $H_{\theta_v, \theta_w} \leftarrow D_v^\top H_{v,w}^f D_w$ 
5:   if  $v = w$  then
6:     for  $i \in 1..d_v$  do
7:        $T_v^\theta \leftarrow \text{autodiff.hessian}(f_{v,i}, \theta_v)$ 
8:        $H_{\theta_v, \theta_v} \leftarrow H_{\theta_v, \theta_v} + T_v^\theta \cdot \delta_{v,i}$ 
9:     end for
10:  end if
11:  for  $u \in \text{Pa}(v) \cap \text{Ch}(w)$  do
12:    for  $i \in 1..d_v$  do
13:      for  $j \in 1..d_u$  do
14:        for  $\alpha \in 1..p_v$  do
15:           $T_{v;u,\theta} \leftarrow \text{ComputeMixedDerivative}(f_{v,i}, f_{u,j}, \theta_{v,\alpha})$ 
16:           $D_{w \leftarrow u} \leftarrow \text{autodiff.jacobian}(f_w, f_u)$ 
17:           $H_{\theta_v, \theta_w} \leftarrow H_{\theta_v, \theta_w} + T_{v;u,\theta} \cdot D_{w \leftarrow u} \cdot \delta_{v,i}$ 
18:        end for
19:      end for
20:    end for
21:  end for
22:  return  $H_{\theta_v, \theta_w}$ 
23: end function

```

Алгоритм 3: Полное вычисление Гессиана

```

1: function FULLHESSIANCOMPUTATION( $G, \{f_v\}, \{\theta_v\}, \mathcal{L}$ )
2:    $\delta_{out} \leftarrow \text{autodiff.gradient}(\mathcal{L}, f_{out})$ 
3:    $H_{out,out}^f \leftarrow \text{autodiff.hessian}(\mathcal{L}, f_{out})$ 
4:    $\text{topo\_order} \leftarrow \text{TopologicalSort}(G).\text{reverse}()$ 
5:   Initialize  $\{\delta_v\}, \{H_{v,w}^f\}$  as zero matrices
6:    $\text{computed\_blocks} \leftarrow \emptyset$  ▷ Отслеживание вычисленных блоков
7:    $\text{input\_dep\_nodes} \leftarrow \text{FindNodesDirectlyInfluencingLoss}(\mathcal{L})$ 
8:   for  $v \in \text{input\_dep\_nodes}$  do
9:      $H_{v,v}^f \leftarrow \text{autodiff.hessian}(\mathcal{L}, f_v)$ 
10:     $\text{computed\_blocks} \leftarrow \text{computed\_blocks} \cup \{(v, v)\}$  ▷ Отметить как
11:    end for
12:    for  $v, w \in \text{input\_dep\_nodes}, v \neq w$  do
13:       $H_{v,w}^f \leftarrow \text{autodiff.mixed\_hessian}(\mathcal{L}, f_v, f_w)$ 
14:       $\text{computed\_blocks} \leftarrow \text{computed\_blocks} \cup \{(v, w)\}$  ▷ Отметить как
15:    end for
16:    for  $v \in \text{topo\_order}$  do
17:       $\text{BackpropagateGradients}(v)$ 
18:      for  $w \in V$  do
19:        if  $\text{Ch}(v) \cap \text{Ch}(w) \neq \emptyset$  OR  $(v, w)$  directly influence  $\mathcal{L}$  then
20:           $H_{v,w}^f \leftarrow \text{ComputeInputHessian}(v, w, \{f_u\}, \mathcal{L}, \{\delta_u\}, \{H_{u,w'}^f\}, \text{computed\_blocks})$ 
21:        end if
22:      end for
23:    end for
24:    Initialize full Hessian matrix  $H$  of size  $P \times P$ 
25:    for  $v, w \in V$  do
26:      if  $\exists u : v \rightarrow^* u$  и  $w \rightarrow^* u$  OR  $(v, w)$  directly influence  $\mathcal{L}$  then
27:         $H_{\theta_v, \theta_w} \leftarrow \text{ComputeParameterHessian}(v, w, \{f_u\}, \{\theta_u\}, \{H_{u,w'}^f\}, \{\delta_u\})$ 
28:        Update corresponding blocks in  $H$ 
29:      end if
30:    end for
31:    return  $H$ 
32: end function

```

В Модульное тестирование реализации

Для проверки корректности предложенной реализации Гессиана необходимы модульные тесты, которые должны включать:

1. Тесты сравнения с аналитическими решениями для простых сетей (например, однослойных перцептронов).
2. Численную проверку симметрии Гессиана в гладком случае.
3. Проверку влияния разреженности графа на вычислительную производительность.
4. Валидацию через численное дифференцирование градиентов.

5. Тестирование с различными активационными функциями (гладкими и негладкими).

Исходный код и CI-процессы доступны по адресу: <https://github.com/username/hessian-computation>.